

企業破產風險預測

不平衡資料下的模型驗證與財務風險指標分析

6,819	93	360	3×3×4
完整企業樣本	候選財務變數	CV 候選／資料版本	模型 × 情境 × 特徵法

馬彥宸

財務金融 × 資料分析 | 2026 年 8 月

本專案依課堂指定模型與特徵方法獨立實作，並自行加入獨立測試集、fold 內資料處理、事前鎖定選模規則與限制分析。目標不是找出『最高 Accuracy』，而是建立一套能說明漏判、誤報與泛化風險的企業風險篩選流程。

作品頁：<https://y3ccc.github.io/projects/bankruptcy-risk/>

01 / EXECUTIVE SUMMARY

先回答決策問題，再談模型。

企業破產資料高度不平衡。若只追求 Accuracy，模型可能幾乎全部預測為健康企業，表面分數很高，卻無法抓到真正需要進一步查核的高風險公司。

本專案要回答什麼？	如何用於決策？
在破產樣本稀少的情況下，如何比較不同模型、抽樣與特徵方法，並把結果轉成可查核的財務風險指標？	適合作為投資前或授信前的初步風險篩選：提高高風險企業的辨識率，再由人工檢視財務、產業與治理資料。不能直接取代投資決策。

三個主要結論

- Accuracy 不能單獨使用：完整資料的破產／健康比例約為 1:30；即使全部預測為健康，Accuracy 仍可接近 97%。
- Recall 上升要與誤報成本一起看：RUS／ADASYN 通常提高破產 Recall，但也可能降低 Precision；因此以 Recall、Precision 與 F1 共同判讀。
- 風險指標集中於幾個財務機制：獲利持續性、負債依賴、資金成本、非本業收益與資本效率在不同方法與抽樣情境中反覆出現。

完整資料版 | Recall 優先規則的三情境平均

59.85%	38.39%	45.18%	95.11%
Test Recall	Test Precision	Test F1	Test Accuracy

這四個數字必須一起看：高 Accuracy 主要受到大量健康企業影響；Recall 與 Precision 才能揭露漏判及誤報取捨。

02 / DATA & DECISION FRAME

先釐清資料版本，避免把課堂加工誤認為原始資料。

分析以課堂提供的企業破產資料為主，並對照 UCI 官方資料頁確認來源背景與公開授權。

資料版本	保留筆數	破產企業	候選特徵	Test 筆數	Test 破產
缺失值清理版	1,736	56	93	348	11
完整資料版	6,819	220	93	1,364	44

資料來源與版本邊界

- UCI 官方資料集為 **Taiwanese Bankruptcy Prediction**，包含 6,819 筆、95 項特徵，來源為 1999–2009 年 Taiwan Economic Journal；破產定義依台灣證券交易所相關規範。
- UCI 官方頁面標示原始資料沒有缺失值，授權為 CC BY 4.0 (DOI: 10.24432/C5004D)。本專案使用的課堂版本另含缺失值，因此只稱為『課堂提供的缺失版』，不推定缺失來自 UCI 原始檔。
- 依題目移除 2 個 flag 欄位與非特徵索引後，留下 93 項候選財務變數。課堂缺失版刪除含缺失值的列後，由 6,819 筆降至 1,736 筆。

為什麼完整資料版更適合討論穩定性？

缺失值清理版的 Test 只有 11 家破產企業，每錯判 1 家，Recall 約變動 9.09 個百分點；完整資料版 Test 有 44 家破產企業，每家約影響 2.27 個百分點。因此缺失版用來完成指定題目，完整資料版才作為模型與 KPI 深入討論主體。

決策邊界

本資料為歷史觀察資料，沒有交易價格、產業景氣、公司治理、技術競爭力或管理團隊品質；模型結果只能做風險篩選，不能單獨回答『是否值得投資』。

03 / RESEARCH DESIGN

課堂指定方法之外，自行補上可驗證的公平比較。

最重要的加值不是多跑模型，而是讓測試集不參與抽樣、標準化、特徵選擇與尋參。

題目原文（原樣引用，讓讀者自行判斷哪些是指定範圍、哪些是我加的）

Considering the dataset, bankruptcy (response is Bankrupt), remove data samples with missing values and apply PCA (cumulative 85% variances) and MI (the same number of features as PCA) to select important indicators (remove all columns containing 'flag'). Then, apply RF and XGB to identify the key performance indicators (cumulative 85% importance). Managerial insights are required to explain causality. Based on these KPIs, compare the performances by using DNN, CNN, and SVM in terms of recall, precision, F measure, and accuracy (positive means bankrupt=1, considering a 5-fold cross validation). Finally, apply RUS and ADASYN to select only 30% healthy firms and mixed with all bankruptcy samples to redo the problem and compare its performance to the original dataset.

課堂題目指定	我自行加入
移除含 flag 欄位；PCA 保留 85% 變異；MI 數量對齊 PCA；RF／XGB 累積 85% 重要度；比較 SVM、DNN、CNN；建立 Original、RUS、ADASYN 三種訓練情境；採 5-fold CV 並報告 Accuracy、Recall、Precision、F1。	共同 untouched test；所有抽樣、標準化與特徵選擇只在 training fold 內 fit；每個資料版本建立 360 組 CV 候選；在開啟 Test 前鎖定 F1 優先與 Recall 優先規則；另做完整資料版本、泛化落差與因果邊界分析。

兩階段公平驗證流程

階段	處理	Test 的角色
1	Stratified 80/20 train/test split	只切分
2	在 CV training fold 內建立 Original／RUS／ADASYN	不參與
3	在 CV training fold 內 fit PCA／MI／RF／XGB	不參與
4	每個組合搜尋 10 組參數並做 5-fold validation	不參與
5	依事前 F1 優先與 Recall 優先規則鎖定候選	不參與
6	以全部 train 重訓；Test 僅最終開啟一次	最終評估

360 組候選如何形成？

每個資料版本包含 3 個模型 × 3 種資料情境 × 4 種特徵方法 × 10 組參數候選，共 360 筆 CV 結果。這些結果是搜尋母體，不是 360 次查看測試集；Test 只在候選鎖定後開啟一次。

防資料洩漏檢查

- 不在切分前使用全資料標準化，也不以全資料挑選特徵。
- RUS/ADASYN 只改變模型 fit 時的 training fold；validation fold 與 Test 保持原分布。
- 不看 Test 結果回頭換模型、調參數或改選模規則。

04 / MODEL RESULTS

最好的模型不是單一答案，而是漏判與誤報之間的選擇。

以下六筆為完整資料版在 Test 開啟前鎖定的候選；三個資料情境共用同一份 holdout。

情境	規則	組合	Test Recall	Test Precision	Test F1	Test Accuracy
Original	F1 優先	CNN+RF	0.3636	0.3810	0.3721	0.9604
Original	Recall 優先	DNN+MI	0.5000	0.5116	0.5057	0.9685
RUS 9:1	F1 優先	DNN+RF	0.6591	0.3625	0.4677	0.9516
RUS 9:1	Recall 優先	CNN+RF	0.6818	0.2752	0.3922	0.9318
ADASYN 9:1	F1 優先	CNN+MI	0.5909	0.3250	0.4194	0.9472
ADASYN 9:1	Recall 優先	CNN+MI	0.6136	0.3649	0.4576	0.9531

三情境平均比較

資料版本	選模規則	Test Recall	Test Precision	Test F1	Test Accuracy
缺失值清理版	F1 優先	0.2121	0.2889	0.2419	0.9579
缺失值清理版	Recall 優先	0.2424	0.2417	0.2304	0.9483
完整資料版	F1 優先	0.5379	0.3562	0.4197	0.9531
完整資料版	Recall 優先	0.5985	0.3839	0.4518	0.9511

為什麼兩版本的差距這麼大？先看每一家的邊際影響

兩版本的 Test Recall 差了約 0.36，但那不代表模型突然變聰明——是分母變了。缺失值清理後只剩 56 家破產公司，Test 裡僅 11 家；判斷錯一家，Recall 就跳動 9.09 個百分點。完整資料版 Test 有 44 家，一家約影響 2.27 個百分點。

換句話說：清理版的分數本身就不穩定，它的高低多半是抽樣噪音而非方法差異。這也是我把主結論建立在完整資料版上的原因。

資料版本	破產樣本數	Test 破產家數	每錯判 1 家的 Recall 變動
缺失值清理版	56	11	約 9.09 個百分點
完整資料版	220	44	約 2.27 個百分點

結果怎麼讀？

- 完整資料版的 Recall 優先平均 Test Recall 為 0.5985，高於 F1 優先的 0.5379；同時 Precision 與 F1 也沒有惡化，顯示這組事前規則在本次 holdout 上取得較佳平衡。
- 單一候選仍有不同取舍：RUS Recall 優先的 Recall 最高（0.6818），但 Precision 僅 0.2752，代表要接受更多誤報。
- Train 指標普遍高於 Test，顯示仍有泛化落差。不能把訓練分數或單次 holdout 結果當成部署績效。

模型與特徵方法的整體傾向（CV 平均，不使用 Test 反向挑選）

下面兩張表把 360 組候選攤開看整體傾向：每格是該模型（或特徵法）跨情境與跨方法的勝出候選之 5-fold validation 算術平均。它回答的是「誰比較穩」，不是「誰贏了」。

資料版本	規則	SVM	DNN	CNN	SVM	DNN	CNN
		CV Recall	CV Recall	CV Recall	CV F1	CV F1	CV F1
缺失值清理版	F1 優先	0.2352	0.3259	0.3574	0.2393	0.3274	0.3454
缺失值清理版	Recall 優先	0.2389	0.3370	0.3648	0.2371	0.3223	0.3388
完整資料版	F1 優先	0.2703	0.3642	0.4066	0.2926	0.3703	0.3728
完整資料版	Recall 優先	0.2718	0.3969	0.4156	0.2884	0.3572	0.3668

資料版本	規則	PCA	MI	RF	XGB	PCA	MI	RF	XGB
		CV Recall	CV Recall	CV Recall	CV Recall	CV F1	CV F1	CV F1	CV F1
缺失值清理版	F1 優先	0.2173	0.3383	0.3235	0.3457	0.2360	0.3212	0.3234	0.3356
缺失值清理版	Recall 優先	0.2247	0.3407	0.3358	0.3531	0.2325	0.3191	0.3123	0.3337
完整資料版	F1 優先	0.3289	0.3550	0.3574	0.3468	0.3269	0.3571	0.3588	0.3383
完整資料版	Recall 優先	0.3422	0.3708	0.3777	0.3550	0.3255	0.3451	0.3455	0.3338

- DNN 與 CNN 的平均 Recall 都高於 SVM；但沒有任何一組模型或特徵法在四項指標上全面勝出。
- PCA 在缺失值清理版明顯落後，在完整資料版才追上——這也支持「樣本數不足才是主要問題」的判斷。
- 這兩張表刻意用 CV 平均而非 Test，因為一旦用 Test 排名，事前鎖定規則就失去意義。

實務判斷

若用於低成本的前端風險篩選，可偏重 Recall；若每一筆誤報都需要昂貴盡職調查，則必須提高 Precision、調整分類門檻，並把人工審查成本納入評估。F1 是平衡指標，但不是所有情境的唯一答案。

05 / STABLE KPIs

把模型重要度轉成值得查核的風險訊號。

以下以完整資料版為主，統計 MI、RF、XGB 在 Original、RUS、ADASYN 三情境的重複入選；最高為 9 次。PCA 只作方法涵蓋補充，不把主成分誤稱為單一 KPI。

穩定 KPI	入選／9	涵蓋方法／4	可能的管理查核方向
Continuous interest rate (after tax)	9	4	檢視資金成本、利息敏感度與再融資空間
Non-industry income and expenditure / revenue	9	4	區分核心營運與非本業收益，檢查盈餘品質
Persistent EPS in the Last Four Seasons	9	3	追蹤獲利持續性，排除一次性利益
Borrowing dependency	9	3	檢視負債依賴、到期集中度與現金流壓力
Net Income to Stockholder's Equity	9	3	結合產業基準觀察資本使用效率
Net profit before tax / Paid-in capital	9	3	檢視稅前獲利與投入資本的關係
Net Income to Total Assets	9	3	觀察資產創造獲利的能力與趨勢
Total income / Total expense	9	3	檢查整體收入對費用的覆蓋與惡化速度

四個可用於人工查核的風險面向

獲利持續性與效率	負債依賴與資金成本
分開檢視持續性獲利與一次性收益，並以資產、權益與投入資本為基準比較。單期比率不足以定論，應結合同業與時間趨勢。	槓桿會放大利率與營收波動對現金流的影響；需要補查債務到期結構、利息保障、契約條款與壓力測試。
非本業收益與盈餘品質	從訊號走向投資評估
非本業收入可能暫時支撐獲利，也可能掩蓋核心營運脆弱；需要拆分處分利益、投資收益與經常性營運結果。	風險指標只能決定『先查什麼』。真正投資評估仍要補上市場規模、競爭優勢、技術、治理、估值、交易條件與退出情境。

因果性邊界

MI、RF／XGB 重要度與 PCA loading 可以說明資料中的關聯與模型使用情形，不能證明改變某一 KPI 必然造成或避免破產。以上管理行動是待查核的機制假說，不是已識別的因果效果。

06 / LIMITS & NEXT STUDY

完成課堂範圍，也清楚標示還不能回答什麼。

目前不需要為了履歷再重跑模型；若要升級為研究或實務工具，下一步應優先補強資料與驗證，而不是只增加模型複雜度。

限制	對結果的影響	可行補強
課堂缺失版刪除 5,083 列	可能存在非隨機缺失偏差，且正類樣本大幅減少	分析缺失機制；採適當插補並做敏感度比較
只有單一 80/20 holdout	結果可能受單次切分影響	Repeated nested CV、bootstrap 信賴區間
缺少異期與外部資料	無法確認跨時間、產業或市場環境的穩定性	時間切分、其他年度或外部企業資料驗證
RUS／ADASYN 改變訓練分布	可能犧牲健康樣本資訊或產生不自然合成樣本	比較 class weight、threshold tuning 與校準
CNN 對非時序特徵使用 kernel size=1	符合教材輸入形式，但不代表財務特徵具有時間順序	以較適合表格資料的模型作強基準
未納入實際誤判成本	無法直接決定最佳門檻或部署規則	以盡調成本、漏判損失建立 cost-sensitive 評估

可延伸的研究題目

- 建立異期驗證：以前期年度訓練、後期年度測試，觀察景氣循環與制度變化下的穩定性。
- 加入可解釋性與校準：檢查個別企業的風險貢獻、預測機率校準與分類門檻，不把重要度當成因果。
- 建立產業分層模型：比較製造、零售、科技等產業是否需要不同財務基準與警戒門檻。
- 把模型輸出轉成盡調清單：將風險訊號連到需補查的財報附註、債務條款、現金流、治理與產業問題。

專案完成定義

已完成：兩個資料版本、四種特徵方法、三種模型、三種資料情境、每個資料版本 360 筆 CV 候選、事前選模規則、Train／Test 評估、穩定 KPI 與限制分析。未完成且不冒稱：外部驗證、部署模型、實際投資績效或因果識別。

參考與查核

UCI Machine Learning Repository | Taiwanese Bankruptcy Prediction：
<https://archive.ics.uci.edu/dataset/572/taiwanese+bankruptcy+pre>

Dataset DOI：<https://doi.org/10.24432/C5004D>

課堂原始作業版、候選結果與中間檔案由作者保留，可於面試時提供查核。