

本報告依題目先完成缺失值清理版，再以同一流程分析 6,819 筆完整資料。兩版本都先切出共同的 untouched test；抽樣、標準化、特徵選擇與尋參只在 training data / CV training fold 內進行。每個資料版本共有 360 筆 CV 候選，但主文只呈現預先規定的 F1 優先與 Recall 優先候選及必要平均，不列出搜尋母體。

完整資料版核心結果

F1 優先規則的三情境平均 Test Recall=0.5379、Precision=0.3562、F1=0.4197；Recall 優先規則則為 Recall=0.5985、Precision=0.3839、F1=0.4518。兩條規則均在 Test 開啟前鎖定，因此可比較其實際代價；不能再從 Test 反向挑參數。

- 缺失值清理版只剩 56 家破產公司，Test 有 11 家；每錯判 1 家，Recall 約變動 9.09 個百分點。
- 完整資料版 Test 有 44 家破產公司，每家約影響 2.27 個百分點，較適合討論模型與特徵方法的穩定關係。
- Train 指標是在完整原始 training split 上評估，RUS / ADASYN 只在模型 fit 時改變訓練資料，讓三情境 Train 指標可直接比較。

1 題目要求與研究設計

1.1 題目原文

Considering the dataset, bankruptcy (response is Bankrupt), remove data samples with missing values and apply PCA (cumulative 85% variances) and MI (the same number of features as PCA) to select important indicators (remove all columns containing 'flag'). Then, apply RF and XGB to identify the key performance indicators (cumulative 85% importance). Managerial insights are required to explain causality. Based on these KPIs, compare the performances by using DNN, CNN, and SVM in terms of recall, precision, F measure, and accuracy (positive means bankrupt=1, considering a 5-fold cross validation). Finally, apply RUS and ADASYN to select only 30% healthy firms and mixed with all bankruptcy samples to redo the problem and compare its performance to the original dataset.

1.2 中文任務拆解

1. 標籤為 Bankrupt?，破產=1；刪除含缺失值的樣本列及欄名含 flag 的欄位。
2. PCA 保留累積 85% 變異；MI 選取與 PCA 相同數量；RF 與 XGB 各累積至 85% 重要度。
3. 以四組特徵分別搭配 SVM、DNN、CNN，以 Stratified 5-fold CV 比較 Recall、Precision、F1 與 Accuracy。
4. 建立 Original、RUS 保留 30% 健康公司、ADASYN 合成破產公司至約 9:1 三情境，完整重做上述流程。
5. 提供 KPI 的管理機制解釋，但把模型重要度視為關聯證據，不誤稱為已識別的因果效果。

1.3 兩階段公平驗證

階段	處理	Test
1	Stratified 80/20 train/test split	只切分
2	CV training fold 內建立 Original/RUS/ADASYN	不參與
3	CV training fold 內 fit PCA/MI/RF/XGB	不參與
4	每個組合搜尋 10 組參數並做 5-fold validation	不參與
5	依事前 F1 優先與 Recall 優先規則鎖定候選	不參與
6	候選以全部 train 重訓，Test 僅最終開啟一次	最終評估

360 組的角色

每個資料版本有 3 模型×3 情境×4 特徵法×10 參數候選=360 筆 CV 結果。它們只是搜尋母體；報告只呈現鎖定候選、代表性模型與平均摘要。

2 資料前處理與特徵選擇

表1 兩個資料版本與共同 train/test

資料集	原始筆數	刪除缺失列	保留筆數	破產	候選特徵	Train	Test	Test 破產
缺失值清理版	6819	5083	1736	56	93	1388	348	11
完整資料版	6819	0	6819	220	93	5455	1364	44

缺失來源檔共有 9,440 個缺失儲存格；刪除任一欄有缺失的列後，由 6,819 筆降至 1,736 筆。兩版本都移除 Liability-Assets Flag、Net Income Flag 與非特徵索引欄，留下 93 個候選原始特徵。

表2 三種訓練情境樣本數；Test 在三情境完全相同

資料集	情境	Train 健康	Train 破產	健康:破產	共同 Test	Test 破產
缺失值清理版	Original	1343	45	29.84:1	348	11
缺失值清理版	RUS 9:1	403	45	8.96:1	348	11
缺失值清理版	ADASYN 9:1	1343	149	9.01:1	348	11
完整資料版	Original	5279	176	29.99:1	1364	44
完整資料版	RUS 9:1	1584	176	9.00:1	1364	44
完整資料版	ADASYN 9:1	5279	587	8.99:1	1364	44

2.1 四種特徵方法

- PCA 是非監督式降維，保留可解釋至少 85% 變異的主成分；輸入模型的是主成分，不是原始 KPI 子集。
- MI 是監督式單變量篩選，數量只與 PCA 對齊；方法與實際入選資訊不同，因此績效不必相同。
- RF、XGB 以監督式樹模型重要度排序原始 KPI，累加至至少 85%。
- 每個 CV training fold 重新 fit 抽樣與 selector，因此 validation fold 不會參與該折的特徵選取。

表3 特徵 / 主成分數及 85% 門檻驗收

資料集	情境	PCA 數	PCA 累積	MI 數	RF 數	RF 累積	XGB 數	XGB 累積
缺失值清理版	Original	32	0.8536	32	64	0.8503	44	0.8568
缺失值清理版	RUS 9:1	27	0.8579	27	58	0.8541	39	0.8532
缺失值清理版	ADASYN 9:1	32	0.8578	32	54	0.8546	36	0.8556

資料集	情境	PCA 數	PCA 累 積	MI 數	RF 數	RF 累積	XGB 數	XGB 累 積
完整資料版	Original	37	0.8512	37	69	0.8515	44	0.8590
完整資料版	RUS 9:1	33	0.8539	33	61	0.8507	44	0.8546
完整資料版	ADASYN 9:1	37	0.8513	37	66	0.8550	37	0.8525

3 缺失值清理版：正式題目結果

此版本完全依題目刪除缺失列。由於 Test 只有 11 家破產公司，以下保留 CV 事前鎖定的 5 筆候選，不把單筆差異解讀成穩定排名。Original 的 F1 / Recall 規則選到同一候選，因此只評估一次。

表 4 缺失值清理版：事前鎖定候選的 CV、Train 與 Test

情境	規則	組合	CV R	CV P	CV F1	Train R	Train P	Train F1	Test R	Test P	Test F1	Test Acc
Original	兩規則相同	CNN + XGB	0.3111	0.3876	0.3298	0.8667	0.7800	0.8211	0.1818	0.3333	0.2353	0.9626
RUS 9:1	F1 優先	CNN + RF	0.4444	0.4265	0.4339	0.5778	0.5000	0.5361	0.2727	0.3333	0.3000	0.9598
RUS 9:1	Recall 優先	CNN + RF	0.5111	0.2969	0.3707	0.9556	0.5000	0.6565	0.1818	0.1250	0.1481	0.9339
ADASY N 9:1	F1 優先	CNN + MI	0.4667	0.4085	0.4326	0.5778	0.4194	0.4860	0.1818	0.2000	0.1905	0.9511
ADASY N 9:1	Recall 優先	SVM + XGB	0.4889	0.3615	0.4114	0.6000	0.4355	0.5047	0.3636	0.2667	0.3077	0.9483

結果解讀

此版最高觀察 Test Recall 為 0.3636，但只代表 11 家破產公司中辨認 4 家；樣本太少，完整版才作為模型與 KPI 深入討論主體。

4 完整資料版：模型比較與最終評估

4.1 每個模型的代表性 CV 組合

為了比較 SVM、DNN、CNN 而不列出全部 360 筆，以下每個情境、每個模型只保留 CV F1 最高的一組特徵與參數，共 9 筆。此表是 5-fold validation 表現，不是 Test 排名。

表 5 完整資料版：每情境×模型的 CV F1 代表組合

情境	模型	CV 最優特徵	CV R	CV P	CV F1	CV Acc
Original	SVM	RF	0.1137	0.6743	0.1931	0.9696
Original	DNN	MI	0.3356	0.3872	0.3515	0.9610
Original	CNN	RF	0.3132	0.4412	0.3616	0.9648
RUS 9:1	SVM	MI	0.3241	0.4305	0.3677	0.9648
RUS 9:1	DNN	RF	0.4319	0.3900	0.4080	0.9593
RUS 9:1	CNN	MI	0.4435	0.3753	0.4040	0.9589
ADASYN 9:1	SVM	MI	0.4090	0.4081	0.4080	0.9615
ADASYN 9:1	DNN	MI	0.4203	0.3963	0.4072	0.9602
ADASYN 9:1	CNN	MI	0.5002	0.3635	0.4202	0.9556

4.2 兩條規則鎖定候選的 Train/Test

表 6 完整資料版：6 筆事前鎖定候選

情境	規則	組合	CV R	CV P	CV F1	Train R	Train P	Train F1	Test R	Test P	Test F1	Test Acc
Original	F1 優先	CNN + RF	0.3132	0.4412	0.3616	0.7784	0.7405	0.7590	0.3636	0.3810	0.3721	0.9604
Original	Recall 優先	DNN + MI	0.3356	0.3872	0.3515	0.7898	0.8081	0.7989	0.5000	0.5116	0.5057	0.9685
RUS 9:1	F1 優先	DNN + RF	0.4319	0.3900	0.4080	0.6591	0.4957	0.5659	0.6591	0.3625	0.4677	0.9516
RUS 9:1	Recall 優先	CNN + RF	0.5065	0.2785	0.3583	0.9432	0.4499	0.6092	0.6818	0.2752	0.3922	0.9318
ADASY N 9:1	F1 優先	CNN + MI	0.5002	0.3635	0.4202	0.6250	0.4280	0.5081	0.5909	0.3250	0.4194	0.9472
ADASY N 9:1	Recall 優先	CNN + MI	0.5113	0.3442	0.4092	0.7102	0.5896	0.6443	0.6136	0.3649	0.4576	0.9531

註：CV 是 validation fold 平均；Train 是最終模型在未抽樣的完整 training split 上之 in-sample 指標；Test 是候選鎖定後才開啟的共同 holdout。Train 高於 Test 顯示仍有泛化落差，不能把 Train 分數當作部署績效。

5 平均績效與抽樣效果

表 7 兩條事前規則的三情境平均

資料集	規則	CV R	CV P	CV F1	Train R	Train P	Train F1	Test R	Test P	Test F1	Test Acc
缺失值清理版	F1 優先	0.4074	0.4075	0.3988	0.6741	0.5665	0.6144	0.2121	0.2889	0.2419	0.9579
缺失值清理版	Recall 優先	0.4370	0.3487	0.3706	0.8074	0.5718	0.6607	0.2424	0.2417	0.2304	0.9483
完整資料版	F1 優先	0.4151	0.3982	0.3966	0.6875	0.5548	0.6110	0.5379	0.3562	0.4197	0.9531
完整資料版	Recall 優先	0.4511	0.3366	0.3730	0.8144	0.6159	0.6841	0.5985	0.3839	0.4518	0.9511




圖1 完整資料版6 筆鎖定候選之 Test Recall 與 F1

5.1 模型平均績效

每格為該模型跨 3 情境×4 特徵法的 12 個 identity 勝出候選之 5-fold validation 算術平均。它回答模型整體傾向，不使用 Test 反向挑選。

表 8 模型平均 CV Recall / F1

資料集	規則	CV Recall			CV F1		
		SVM	DNN	CNN	SVM	DNN	CNN
缺失值清理版	F1 優先	0.2352	0.3259	0.3574	0.2393	0.3274	0.3454
缺失值清理版	Recall 優先	0.2389	0.3370	0.3648	0.2371	0.3223	0.3388
完整資料版	F1 優先	0.2703	0.3642	0.4066	0.2926	0.3703	0.3728
完整資料版	Recall 優先	0.2718	0.3969	0.4156	0.2884	0.3572	0.3668

5.2 特徵方法平均績效

每格為該特徵法跨 3 情境×3 模型的 9 個 identity 勝出候選之 5-fold validation 算術平均。PCA 與 MI 數量相同，但資訊保留原理不同，平均績效因此可不同。

表 9 特徵方法平均 CV Recall / F1

資料集	規則	CV Recall				CV F1			
		PCA	MI	RF	XGB	PCA	MI	RF	XGB
缺失值清理版	F1 優先	0.2173	0.3383	0.3235	0.3457	0.2360	0.3212	0.3234	0.3356
缺失值清理版	Recall 優先	0.2247	0.3407	0.3358	0.3531	0.2325	0.3191	0.3123	0.3337
完整資料版	F1 優先	0.3289	0.3550	0.3574	0.3468	0.3269	0.3571	0.3588	0.3383
完整資料版	Recall 優先	0.3422	0.3708	0.3777	0.3550	0.3255	0.3451	0.3455	0.3338

6 重要 KPI 與管理意涵

下表以完整資料版為主，統計 MI、RF、XGB 在 Original、RUS、ADASYN 三情境的重複入選。最高入選次數為 3 方法×3 情境=9；PCA 只以原始變數對保留主成分的加權貢獻補充『方法涵蓋數』，不把主成分誤稱為單一原始 KPI。

表 10 完整資料版跨情境穩定 KPI

KPI	入選次數 /9	涵蓋方法 /4	平均名次	平均重要度
Continuous interest rate (after tax)	9	4	8.4	0.0334
Non-industry income and expenditure/revenue	9	4	13.6	0.0258
Persistent EPS in the Last Four Seasons	9	3	1.8	0.0474
Borrowing dependency	9	3	3.9	0.0353
Net Income to Stockholder's Equity	9	3	6.2	0.0332
Net profit before tax/Paid-in capital	9	3	8.1	0.0232
Net Income to Total Assets	9	3	12.4	0.0224
Total income/Total expense	9	3	14.3	0.0222

6.1 管理機制假說

面向	代表 KPI	可能機制與管理行動
獲利持續性	Persistent EPS、Net Income / Assets、Retained Earnings / Assets	持續獲利與內部累積資金不足時，吸收營運衝擊的緩衝較小；應分開監控一次性獲利與持續性獲利。
負債依賴	Borrowing dependency、Debt ratio、DFL	槓桿提高會放大利率與營收變動對現金流的影響；應追蹤再融資空間、債務到期集中度與壓力測試。
利息與非本業	Continuous interest rate、Non-industry income / revenue	資金成本上升或過度依賴非本業收益，可能掩蓋核心營運脆弱；應檢視利息敏感度與盈餘品質。
股東報酬與效率	Net Income / Equity、Pre-tax profit / paid-in capital	資本使用效率惡化會削弱權益緩衝；應結合產業基準與趨勢觀察，不以單期比率直接下結論。

因果性邊界

本資料為觀察型企業財務資料。MI、樹模型重要度與 PCA loading 能說明關聯與模型使用情形，不能單獨證明改變某 KPI 必然造成或避免破產；本節是可檢驗的管理機制假說，而非已識別的因果效果。

7 結論、限制與執行狀態

7.1 主要結論

1. PCA、MI、RF、XGB 均依題目完成，6 個資料集×情境組合皆通過 MI=PCA 數量及 85% 門檻。
2. 完整資料版中，兩條事前規則都顯示 RUS / ADASYN 可提高破產 Recall，但 Recall 增加常伴隨 Precision 下降；應以 Recall 與 F1 一起判讀。
3. 完整資料的 Test 波動明顯小於缺失清理版，顯示保留資訊與正類樣本數是本題最重要的穩定性來源。
4. DNN / CNN 的平均 Recall 高於 SVM；MI / RF 在完整資料的平均 F1 較具競爭力，但沒有單一方法在所有情境固定勝出。
5. 高度重複入選 KPI 集中於獲利持續性、負債依賴、資金成本、非本業收益與資本效率，可作為風險監控優先順序。

7.2 限制

- 缺失清理刪除 5,083 列，可能產生非隨機缺失偏差；因此其結果只作題目正式回答，不過度解讀細微差距。
- 目前只有單一 80/20 holdout；5-fold CV 降低尋參偶然性，但不能取代異期或外部資料驗證。
- RUS 犧牲部分健康樣本，ADASYN 產生合成破產樣本；兩者都可能改變決策邊界，須以 untouched Test 監督泛化。
- CNN 將非時序金融特徵表示為（樣本數, 1, 特徵數），kernel size=1；它符合教材 Keras 輸入形式，但不代表特徵存在時間順序。

7.3 是否還需要重跑

作業必要範圍：已完成

目前不需要再重跑模型：兩資料版本均已有 360 筆 5-fold CV 候選、事前 selection manifest、Train/Test 最終評估、四種特徵法、三模型、三情境與 Accuracy / Recall / Precision / F1。若未來要做研究級補強，可另跑 repeated nested CV 或外部時間切分；它們是選做，不是本題缺漏。

完整候選、特徵清單、PCA loading 與超參數仍保存在 Q3_results / JSON / CSV 中供查核，但依精簡要求不放入本 Word，也不建立附錄。